Práctica 2 - Tika

Ejercicio 1: Abrir un archivo pdf en el modo ventana y decir quién es el autor del archivo, si tiene.

Primero ejecutamos el modo ventana abriendo un "cmd" en la misma pestaña que contiene el fichero .jar y ejecutando la orden: "java -jar tika-app-2.9.1.jar". Con el modo ventana abierto, vamos a File > Open... y seleccionamos el fichero que deseamos (en este caso selecciono el documento que realice para la anterior práctica) ver Figura 1 y 2.

Como podemos ver en la Figura 3, en el apartado "dc:creator" obtenemos el autor del documento.

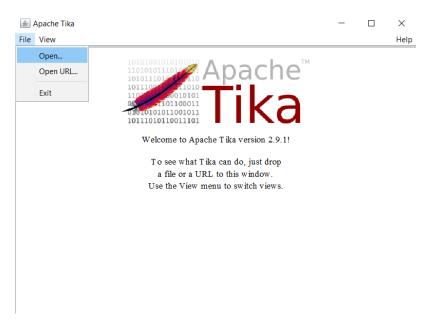


Figura 1 Modo ventana de Tika (apartado open)

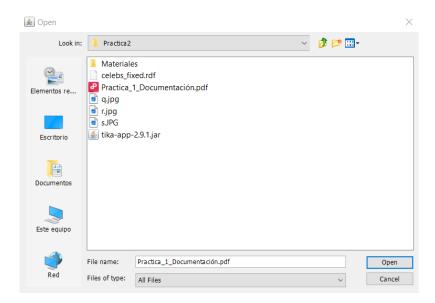


Figura 2 Selección del fichero

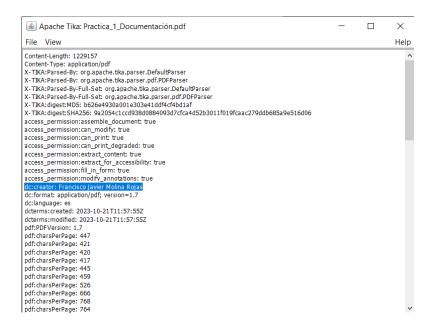


Figura 3 Creador del documento

Ejercicio 2: Almacenar el contenido de un archivo .pdf en un archivo .doc.

Para obtener el contenido de un fichero ejecutaremos el fichero jar con la misma orden que en el apartado anterior, pero a esta le agregaremos la flag "--text" junto al fichero del que queramos obtener el contenido. Si dejásemos esto, la consola se llenaría con el contenido del fichero, así que usaremos el operador > para redirigir el flujo de salida a un fichero llamado test.doc, ver Figura 4.

En la Figura 5 y 6 podemos ver el contenido del fichero .pdf y del fichero . doc resultante.

```
C:\Users\javie\OneDrive\Escritorio\REC-INF\Practica2>java -jar tika-app-2.9.1.jar --text Practica_1_Documentación.pdf > test2.doc
C:\Users\javie\OneDrive\Escritorio\REC-INF\Practica2>
```

Figura 4 Comando usado para obtener el contenido del fichero .pdf

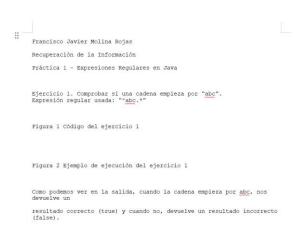


Figura 5 Contenido de test2.doc

```
Practica 1 - Expresiones Regulares en Java

Ejercicio 1. Comprobar si una cadena empieza por "abe".

Expresión regular usada: "^abe. *"

J egrecos Java * 

J egrecos
```

Figura 6 Contenido del fichero .pdf

Ejercicio 3: Ver los metadatos de un archivo que esté subido en una página web.

Para este ejercicio, usaremos el siguiente enlace que contiene un pdf: https://esingenieria.uca.es/wp-content/uploads/2023/11/Convocatoria-elecciones-Delegado-curso-23-24.report.pdf, ver Figura 7.

En este caso además del comando "java -jar tika-app-2.9.1.jar" le añadimos la flag "--metadata" y la web, obteniendo como resultado los metadatos de la misma como podemos ver en la Figura 8.



Figura 7 Archivo web

```
C: Ubsers\javis\(\text{Ontent\text{Veritorio\text{NEC-INF\Practica2}\)java -jar tika-app-2.9.1. jar --metadata https://esingenieria.uca.es/wp-content/uploads/2023/11/Convocatoria-elecciones-Delegado-curso-23-24.report.pd
Content-lype: application/pdf
X: TIKA-Parsed By: org.apache.tika.parser.DefaultParser
X: TIKA-Parsed By: org.apache.tika.parser.DefaultParser
descess.permission:casephic document: true
access.permission:casephic document: true
access.permission:can.print_degraded: true
access.permission:can.print_degraded: true
access.permission:can.print_ofgraded: true
access.permission:can.print_ofgraded:
access.permission:can.prin
```

Figura 8 Resultado del comando

Ejercicio 4: Comprimir un archivo de texto sencillo y abrir con Tika el archivo comprimido.

Creamos un fichero .txt con contenido en el mismo directorio donde guardamos en fichero pika, ver Figura 9.

Posteriormente, lo comprimimos el archivo en un .zip, ver Figura 10.

Por último, realizamos el comando "java -jar tika-app-2.9.1.jar" junto el archivo .zip, ver Figura 11.

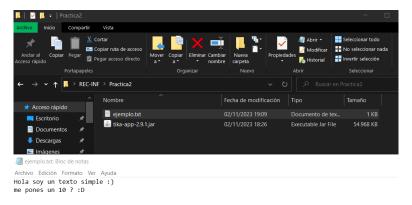


Figura 9 Fichero .txt

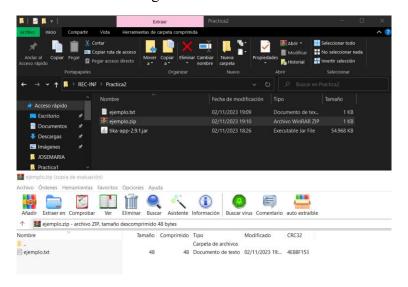


Figura 10 Fichero .txt comprimido

```
C:\Users\javie\OneDrive\Escritorio\REC-INF\Practica2>java -jar tika-app-2.9.1.jar ejemplo.zip
<?xml version="1.0" encoding="UTF-8"?>khtml xmlns="http://www.w3.org/1999/xhtml">
<head>
<meta name="X-TIKA:Parsed-By" content="org.apache.tika.parser.DefaultParser"/>
<meta name="X-TIKA:Parsed-By" content="org.apache.tika.parser.pkg.PackageParser"/>
<meta name="resourceName" content="ejemplo.zip"/>
<meta name="Content-Length" content="204"/>
<meta name="Content-Type" content="application/zip"/>
<fitle/>
</head>
</head>
<head>
<h
```

Figura 11 Resultado del comando

Ejercicio 5: Pasar por correo y Whatsapp una foto y comparar los metadatos comprobando las diferencias.

Descargamos y almacenamos las fotos en el mismo repositorio que almacena el fichero .jar, ver Figura 12.

Posteriormente, realizamos dos comandos con "java -jar tika-app-2.9.1.jar" junto con el flag "--metadata" y cada una de las dos imágenes.

Finalmente, como vemos en las Figuras 13 y 14, la foto enviada por WhatsApp tiene menos metadatos que la enviada por correo. Esto es debido a la compresión que realiza WhatsApp al mandar cualquier tipo de foto.

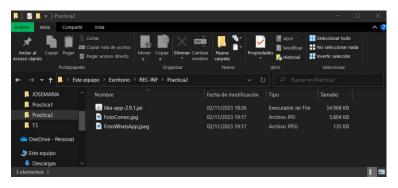


Figura 12 Fotos en el directorio

```
Component 1: V component (Quantization table 9, Sampling factors ) and prize (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for locally vert (Quantization table 19, Sampling factors ) for lo
```

Figura 13 Metadatos de la foto por correo

Francisco Javier Molina Rojas

```
C:\Users\javis\\text{Somming through Excitorio\MC-IMF\Practica?}\) jour -jar-tike app-2,9.1.jar-metadata fotoMutukpp.jpng
Component 1: Occupionett (Quantization table 6), Sampling factors 2 horiz/2 vert
Component 3: Or Component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Or Component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Or Component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Or Component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Or Component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Or Component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Or Component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Or Component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Or Component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Or Component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Or Component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Or Component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Or Component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Or Component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Or Component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Or Component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component: Quantization tab
```

Figura 14 Metadatos de la foto por WhatsApp

Ejercicio 6: Ver los metadatos de http://www.uca.es/es/ y guardarlo en un archivo.txt.

Primero, realizamos el comando "java -jar tika-app-2.9.1.jar" junto con el flag "--metadata" y con la url desada, además de usar el operador > para redirigir el flujo de salida a un fichero llamada "archivo.txt", ver Figura 15.

Por último, podemos ver los metadatos de la url en dicho fichero, ver Figura 16.

```
C:\Users\javie\OneDrive\Escritorio\REC-INF\Practica2>java -jar tika-app-2.9.1.jar --metadata https://www.uca.es > archivo.txt
C:\Users\javie\OneDrive\Escritorio\REC-INF\Practica2>
```

Figura 15 Comando realizado

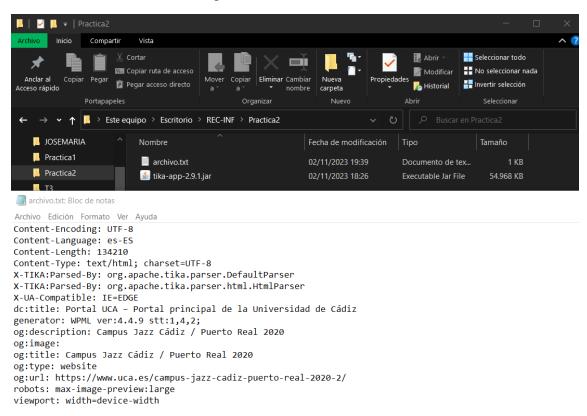


Figura 16 Contenido de archivo.txt

Ejercicio 7: Pasar un archivo .rdf a .doc. ¿Pasar el archivo .doc o .rdf al formato .pdf dará error?

Primero realizaremos el paso de .rdf a .doc, como podemos ver en la Figura 17, con el comando "java -jar tika-app-2.9.1.jar", el flag "--text" y el operador > para redirigir el flujo a un fichero test.doc.

Si vemos el contenido de este fichero obtendríamos lo que se ve en la Figura 18.

Si intentamos pasar este .rdf a .pdf, como podemos ver en la Figura 19, con el comando comando "java -jar tika-app-2.9.1.jar", el flag "--text" y el operador > para redirigir el flujo a un fichero test.pdf, podremos ver en la Figura 20 que al intentar acceder a su información, este estará corrupto y no permitirá acceder al mismo.

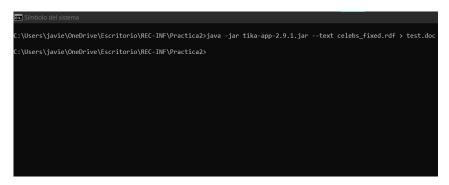


Figura 17 Comando para pasar de .rdf a .doc



Figura 18 Contenido de test.doc

```
C:\Users\javie\OneDrive\Escritorio\REC-INF\Practica2>java -jar tika-app-2.9.1.jar --text celebs_fixed.rdf > test.pdf
C:\Users\javie\OneDrive\Escritorio\REC-INF\Practica2>
```

Figura 19 Comando para pasar de .rdf a .pdf



Figura 20 Fichero test.pdf corrupto

Ejercicio 8: Descargar las 3 imágenes que se proporcionan en la carpeta "Material Tika" y decir qué imagen (o imágenes) se sacó (sacaron) con un producto perteneciente a apple computer inc.

Como podemos ver en las Figuras 21, 22 y 23 (metadatos de cada imagen), solo la imagen q y r están realizadas con un producto perteneciente a Apple.

```
C:\Users\javie\OneDrive\Escritorio\REC-INF\Practica2>java -jar tika-app-2.9.1.jar --metadata s.JPG
AE Warning: AE Good
Auto Bracketing: Off
Blur Warning: No Blur Warning
Color Saturation: Normal
Component 1: Y component: Quantization table 0, Sampling factors 2 horiz/1 vert
Component 2: Cb component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cr component: Quantization table 2, Sampling factors 1 horiz/1 vert
Compression Type: Baseline
Content-Length: 2554023
Content-Type: image/jpeg
Data Precision: 8 bits
Dynamic Range: Standard
Exif IFD0:Copyright:
Exif IFD0:Date/Time: 2006:04:25 14:42:14
Exif IFD0:Model: FinePix A500
Exif IFD0:Model: FinePix A500
Exif IFD0:Model: FinePix A500
Exif IFD0:Software: Digital Camera FinePix A500 Ver1.03
Exif IFD0:Software: Digital Camera FinePix A500 Ver1.03
Exif IFD0:Y Resolution: 72 dots per inch
Exif SubIFD:Aperture Value: f/4,9
Exif SubIFD:Aperture Value: f/4,9
Exif SubIFD:Color Space: 8KGB
Exif SubIFD:Color Space: 8KGB
Exif SubIFD:Components Configuration: YCbCr
```

Figura 21 Metadatos de la imagen s

```
C:\Users\javie\OneDrive\Escritorio\REC-INF\Practica2>java -jar tika-app-2.9.1.jar --metadata q.jpg
Component 1: Y component: Quantization table 0, Sampling factors 2 horiz/2 vert
Component 3: Cr component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cr component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cr component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cr component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cr component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cr component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cr component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cr component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cr component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cr component: Quantization table 1, Sampling factors 1 horiz/1 vert
Conponent 3: Cr component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 2: Cr component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 2: Cr component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 2: Cr component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cr component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cr component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cr component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cr component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cr component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cr component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cr component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cr compon
```

Figura 22 Metadatos de la imagen q

```
C:\Users\javie\OneDrive\Escritorio\REC-INF\Practica2>java -jar tika-app-2.9.1.jar --metadata r.jpg
Component 1: Unknown (0) component: Quantization table 0, Sampling factors 2 horiz/2 vert
Component 2: Y component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cb component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cb component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cb component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cb component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cb component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cb component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cb component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cb component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cb component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 2: V component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 2: V component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 2: V component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 2: V component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 2: V component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 2: Vert
Component 3: Cb component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 2: Vert
Component 2: Vert
Component 3: Vert
Component 2: Vert
Component 2: Vert
Component 2: Vert
Component 3: Vert
Component 2: Vert
Component 3: Vert
Component 2: Vert
Component 4: Vert
Component 6: Vert
Component
```

Figura 23 Metadatos de la imagen r

Ejercicio 9: Describir el procedimiento seguido para guardar el contenido de una web cualquiera en un archivo html, este convertirlo en doc y comprobar los metadatos de este último.

Para pasar el contenido de la web a un archivo html, usaremos el comando "java -jar tika-app-2.9.1.jar" y el operador > para redirigir el flujo de salida hacia un archivo llamado webEsi.html, ver Figura 24.

Como podemos ver en la Figura 25 se obtiene el formato html de la web.

Para pasar el archivo html a doc, usaremos el comando "java -jar tika-app-2.9.1.jar" y el operador > para redirigir el flujo de salida hacia un archivo llamado test.doc, ver Figura 26.

En la Figura 26, podemos ver el contenido de test.doc.

Por ultimo para visualizar los metadatos de este ultimo fichero, usaremos el comando "java -jar tika-app-2.9.1.jar", el flag "--metadata" y el fichero test.doc, ver Figura 27

```
C:\Users\javie\OneDrive\Escritorio\REC-INF\Practica2>java -jar tika-app-2.9.1.jar https://esingenieria.uca.es/ > webEsi.html
C:\Users\javie\OneDrive\Escritorio\REC-INF\Practica2>
```

Figura 24 Comando pasar de web a html

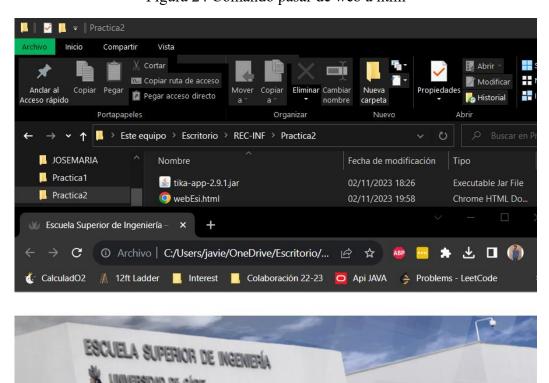


Figura 25 Muestra del html

```
C:\Users\javie\OneDrive\Escritorio\REC-INF\Practica2> java -jar tika-app-2.9.1.jar webEsi.html > test.doc
.
.C:\Users\javie\OneDrive\Escritorio\REC-INF\Practica2>
```

Figura 26 Comando pasar de html a doc

Figura 27 Contenido test.doc

```
:\Users\javie\OneDrive\Escritorio\REC-INF\Practica2> java -jar tika-app-2.9.1.jar --metadata test.doc
Content-Encoding: UTF-8
Content-Encoding: UTF-8
Content-Encoding: UTF-8
Content-Language: es-ES
Content-Language: es-ES
Content-Language: es-ES
Content-Length: 33186
Content-Length: 32663
Content-Length: 70849
Content-Type: application/xhtml+xml; charset=UTF-8
Content-Type-Hint: application/xhtml+xml; charset=UTF-8
X-TIKA:Parsed-By: org.apache.tika.parser.DefaultParser
X-TIKA:Parsed-By: org.apache.tika.parser.html.HtmlParser
X-TIKA:Parsed-By: org.apache.tika.parser.DefaultParser
K-TIKA:Parsed-By: org.apache.tika.parser.html.HtmlParser
X-TIKA:Parsed-By: org.apache.tika.parser.DefaultParser
X-TIKA:Parsed-By: org.apache.tika.parser.html.HtmlParser
X-UA-Compatible: IE=EDGE
dc:title: Escuela Superior de Ingenier¦¡a ÔÇô Sitio web de la Universidad de C¦ídiz
generator: WPML ver:4.0.7 stt:1,2;
og:description: Grados
og:title: Grados
og:type: website
og:url: https://esingenieria.uca.es/grados/
resourceName: test.doc
resourceName: webEsi.html
robots: max-image-preview:large
viewport: width=device-width
:\Users\javie\OneDrive\Escritorio\REC-INF\Practica2>
```

Figura 28 Metadatos de test.doc

Ejercicio 10: Descargar tres imágenes, a elección del alumno, de tres sitios diferentes donde los usuarios compartan imágenes como pueden ser: facebook, instagram, flickr, twitter... y comentar las diferencias que encontramos en los metadatos.

Como podemos ver en las Figuras 29 y 30 (pertenecientes a Twitter), la Figura 31 (perteneciente a Facebook) y la Figura 32 (perteneciente a Pinterest); las principales diferencias que poseen son: Las fotos de Twitter y Facebook poseen información relativa al RGB, cosa que la de Pinterest no posee. Además, las fotos de Facebook y Twitter poseen una longitud superior a la de Pinterest.

```
Components 1. Concentration table 1. Sampling factors 1 horiz/1 vert
Components 2. Characteristic Quantization table 1. Sampling factors 1 horiz/1 vert
Components 2. Characteristic Quantization table 1. Sampling factors 1 horiz/1 vert
Components 2. Characteristic Quantization table 1. Sampling factors 1 horiz/1 vert
Components 2. Characteristic Quantization table 1. Sampling factors 1 horiz/1 vert
Components 2. Characteristic Quantization table 1. Sampling factors 1 horiz/1 vert
Components 2. Characteristic Quantization table 1. Sampling factors 1 horiz/1 vert
Components 2. Characteristic Quantization table 1. Sampling factors 1 horiz/1 vert
Components 2. Characteristic Quantization table 1. Sampling factors 1 horiz/1 vert
Components 2. Characteristic Quantization table 2. Char
```

Figura 29 Metadatos foto Twitter I

```
CC:Signature: acsp
CC:Tag Count: 17
CC:Technology: CRT
CC:Version: 2.1.0
CC:Viewing Conditions: view (0x76696577): 36 bytes
ICC:Viewing Conditions Description: Reference Viewing Condition in IEC61966-2.1
CC:XYZ values: 0,964 1 0,825
mage Height: 680 pixels
mage Width: 680 pixels
lumber of Components: 3
lumber of Tables: 2 Huffman tables
Resolution Units: none
humbnail Height Pixels: 0
humbnail Width Pixels: 0
ersion: 1.1
Resolution: 1 dot
-TIKA:Parsed-By: org.apache.tika.parser.DefaultParser
-TIKA:Parsed-By: org.apache.tika.parser.image.JpegParser
Resolution: 1 dot
esourceName: FotoTwitter.jfif
iff:BitsPerSample: 8
iff:ImageLength: 680
iff:ImageWidth: 680
:\Users\javie\OneDrive\Escritorio\REC-INF\Practica2>
```

Figura 30 Metadatos foto Twitter II

Francisco Javier Molina Rojas

```
Component 1: Or component: Quantization table 0, sampling factors 2 fortize event (component 2: Che component 2: Che component 2: Che component 3: Che componen
```

Figura 31 Metadatos foto Facebook

```
C:\Users\javie\OneDrive\Escritorio\REC-INF\Practica2>java -jar tika-app-2.9.1.jar --metadata FotoPinterest.jpg
Component 1: Y component: Quantization table 0, Sampling factors 2 horiz/2 vert
Component 2: Cb component: Quantization table 1, Sampling factors 1 horiz/1 vert
Component 3: Cr component: Quantization table 1, Sampling factors 1 horiz/1 vert
 Compression Type: Progressive, Huffman
Content-Length: 76956
Content-Type: image/jpeg
Data Precision: 8 bits
File Modified Date: vie nov 03 09:22:01 +01:00 2023
File Name: FotoPinterest.jpg
File Size: 76956 bytes
Image Height: 564 pixels
Image Width: 564 pixels
Number of Components: 3
Number of Components. 3
Number of Tables: 2 Huffman tables
Resolution Units: inch
Thumbnail Height Pixels: 0
Thumbnail Midth Pixels: 0
Version: 1.1
X Resolution: 72 dots
X-TIKA:Parsed-By: org.apache.tika.parser.DefaultParser
X-TIKA:Parsed-By: org.apache.tika.parser.image.JpegParser
Y Resolution: 72 dots
 resourceName: FotoPinterest.jpg
tiff:BitsPerSample: 8
tiff:ImageLength: 564
tiff:ImageWidth: 564
  :\Users\javie\OneDrive\Escritorio\REC-INF\Practica2>
```

Figura 32 Metadatos foto Pinterest

Ejercicio 11: Se puede trabajar con Tika desde Eclipse. Describe los pasos que han de realizarse para poder crear un proyecto Tika en Eclipse en el que se extraiga el contenido de un fichero PDF.

Primero, una vez instalado eclipse, creamos un proyecto java y desmarcamos la opción "create module-info.java file", ver Figura 33.

Después creamos en el directorio "src" un fichero clase con el nombre "ExtraerPdf", ver Figura 34 y 35.

Posteriormente, añadimos en el build path el fichero .jar de Tika para añadir sus librerías, ver Figura 36 y 37.

Con esto ya podríamos crear nuestro script (explicación a continuación): Se instancia un objeto de la clase File de java con la referencia al fichero deseado (path hacia el fichero), se instancia un objeto de la clase Tika, definimos una variable String que almacene el contenido del fichero y para obtener este, usamos el método parseToString() de la clase Tika, que recibe un fichero de entrada y devuelve su contenido. Por ultimo se imprime por pantalla el contenido. Para una visualización del código ver Figura 38.

Por último, ejecutamos el código de "ExtraerPdf.java" y obtendremos en la consola de salida el contenido del pdf, ver Figura 39.

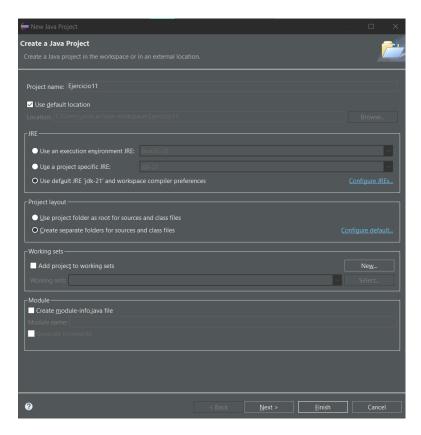


Figura 33 Creación del proyecto

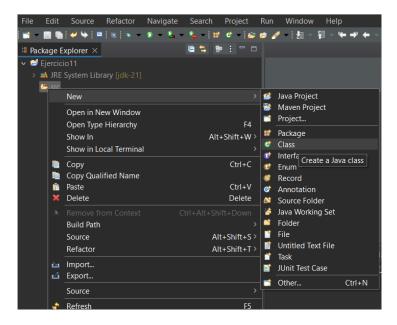


Figura 34 Creacion del fichero class I

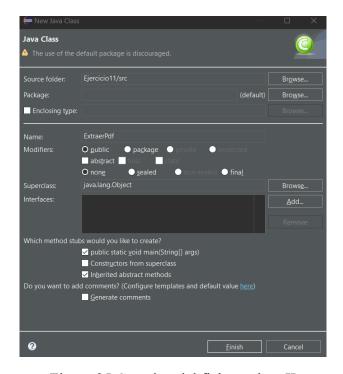


Figura 35 Creacion del fichero class II

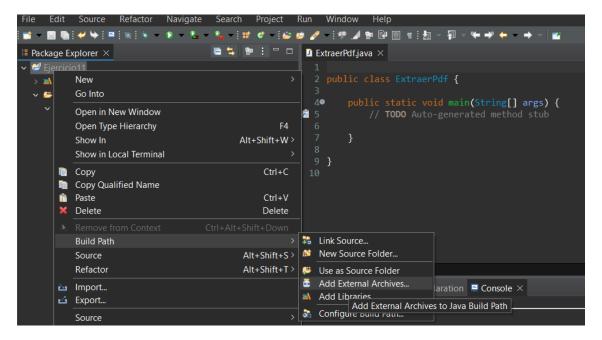


Figura 36 Añadir el fichero jar al Build Path I

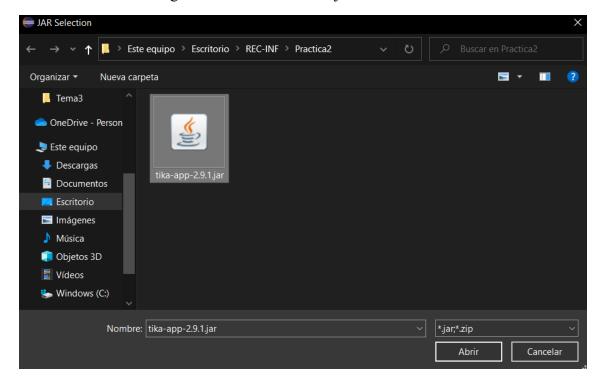


Figura 37 Añadir el fichero jar al Build Path II

Figura 38 Código de ExtraerPdf.java

Figura 39 Salida por consola (contenido del pdf)